

DATA_SOURCES.md

Ce document recense le jeu de données utilisé pour entraîner et évaluer le pipeline HTR du projet **htr-ndp-cursive-evolution-2026**, dans le cadre du module *Vision par ordinateur* (Master Data/IA, HETIC, 2026).

Conformément à la contrainte n°7 du brief de projet, seul du matériel diffusé sous licence libre est utilisé. Le corpus retenu est intégralement sous licence Creative Commons CC-BY 4.0.

Axe de recherche et choix du corpus

Question scientifique. Un modèle HTR entraîné sur la cursive notariale du XIV^e siècle généralise-t-il à la cursive du XV^e-XVI^e siècle, malgré l'évolution paléographique de l'écriture sur deux siècles ?

Choix méthodologique. Plutôt que de mobiliser plusieurs corpus hétérogènes (différents projets, conventions, types documentaires), nous avons choisi de focaliser le travail sur **un seul corpus mono-source**, dont la profondeur temporelle (1326-1504) permet précisément de répondre à la question diachronique posée. Ce choix de profondeur sur largeur est cohérent avec les recommandations actuelles en humanités numériques (Torres Aguilar, *TRIDIS*, 2025) qui valorisent la cohérence et la qualité des annotations sur le volume brut.

Corpus retenu : ANR e-NDP Ground Truth

Description. Vérité terrain HTR issue du projet ANR e-NDP (« Notre-Dame de Paris et son cloître »), édition numérique collaborative des registres capitulaires de la cathédrale Notre-Dame de Paris. Porté par le LaMOP (Université Paris 1 Panthéon-Sorbonne) sous la direction de Julie Claustre et Darwin Smith, en partenariat avec les Archives nationales, la Bibliothèque nationale de France, l'École nationale des chartes et la Bibliothèque Mazarine.

Le corpus rassemble 512 pages représentatives des 26 registres médiévaux du chapitre, conservés aux Archives nationales sous les cotes AN LL 105-128. Les transcriptions ont été réalisées entre 2021 et 2022 par 12 paléographes et historiens, en deux tours de relecture, via l'interface eScriptorium.

Métadonnée	Valeur
Période couverte	1326–1504 (XIV ^e –XVI ^e siècle)
Langue(s)	Latin médiéval (≥ 98 %), français (≤ 2 %)
Famille d'écriture	Cursive médiévale (cf. fiche Zenodo : <i>Cursive script, late XIII^e–XVI^e</i>)
Type de documents	Registres administratifs (délibérations capitulaires)
Volume	34 231 lignes / 3 320 407 caractères / 512 pages
Nombre de mains identifiées	18 mains principales
Convention de transcription	Semi-diplomatique, abréviations résolues
Format de livraison	PAGE XML + JPG/JPEG
Licence	Creative Commons CC-BY 4.0
Dépôt Zenodo	https://zenodo.org/records/7575693
DOI	10.5281/zenodo.7575693
Code des modèles HTR du projet	https://github.com/chartes/e-NDP_HTR
Taille de l'archive	913,8 Mo (ZIP)

Justification du choix de la langue latine majoritaire

Le brief impose un périmètre « XI^e-XVII^e siècle, vieux/moyen français ». L'inclusion d'e-NDP, dont le contenu est majoritairement latin, se justifie par le **recentrage paléographique** de notre projet : notre axe de recherche porte sur l'évolution de l'écriture cursive en tant que forme graphique, et non sur la langue sous-jacente. Le latin médiéval écrit en France et l'ancien français partagent la même tradition graphique (cursives, ligatures, systèmes d'abréviation), et un modèle HTR opère sur les formes visuelles des glyphes indépendamment du contenu lexical. Cette approche est cohérente avec les pratiques actuelles en HTR médiévale (Torres Aguilar, 2025 ; Pinche et al., 2023).

Citation académique (APA)

Claustre, J., Smith, D., Torres Aguilar, S., Bretthauer, I., Brochard, P., Canteaut, O., Cottereau, E., Delivré, F., Denglos, M., Jolivet, V., Julerot, V., Kouamé, T., Lusset, E., Massoni, A., Nadiras,

S., Perreaux, N., Regazzi, H., & Treglia, M. (2023). *The e-NDP project: collaborative digital edition of the Chapter registers of Notre-Dame of Paris (1326-1504). Ground-truth for handwriting text recognition (HTR) on late medieval manuscripts* (Version 1.0) [Dataset]. Zenodo. <https://doi.org/10.5281/zenodo.7575693>

Citation académique (BibTeX)

@dataset{claustre_endp_2023,

author = {Claustre, Julie and Smith, Darwin and Torres Aguilar, Sergio
and Bretthauer, Isabelle and Brochard, Pierre
and Canteaut, Olivier and Cottureau, Emilie and Delivré, Fabrice
and Denglos, Mathilde and Jolivet, Vincent and Julerot, Véronique
and Kouamé, Thierry and Lusset, Elisabeth and Massoni, Anne
and Nadiras, Sebastien and Perreaux, Nicolas and Regazzi, Hugo
and Treglia, Mathilde},

title = {The e-NDP project: collaborative digital edition of the Chapter
registers of Notre-Dame of Paris (1326-1504). Ground-truth for
handwriting text recognition (HTR) on late medieval manuscripts},

year = {2023},

version = {1.0},

publisher = {Zenodo},

doi = {10.5281/zenodo.7575693}

}

Financement à mentionner

Agence Nationale de la Recherche, projet **ANR-20-CE27-0012** (« e-NDP : Notre-Dame de Paris and its cloister »).

Conformité licencielle

Le corpus e-NDP est diffusé sous **licence Creative Commons Attribution 4.0 International (CC-BY 4.0)**. Cette licence autorise la redistribution, la modification et l'usage commercial des données, sous réserve de mentionner correctement les auteurs originaux. Le présent projet respecte cette obligation par la citation ci-dessus et par le fichier **MODEL_CARD.md** du dépôt.

Aucune source protégée par le droit d'auteur ou diffusée sous licence restrictive (CC-BY-NC, CC-BY-ND, propriétaire) n'a été utilisée.

Attribution dans les publications

Toute publication issue du présent projet (article scientifique, modèles dérivés, jeux de données augmentés) doit mentionner explicitement :

1. **L'équipe e-NDP** : Julie Claustre, Darwin Smith et l'ensemble des contributeurs (LaMOP, Université Paris 1 Panthéon-Sorbonne), financement ANR-20-CE27-0012.
2. **L'écosystème HTR-United** (Chagué, Clérice, Chiffolleau, 2021) comme infrastructure ayant permis la mise à disposition de la ressource.